

Analisi delle prestazioni di inserimento in Alberi Binari di Ricerca

Stefano Londero
172585

Federico Alfio Grasso
173731

Contents

1	Introduzione	2
2	Richiami Teorici	2
3	Struttura del Progetto	2
4	Algoritmo	3
5	Risultati e Analisi	4
5.1	Grafico Principale	4
5.2	Grafico dell'analisi asintotica	5
5.3	Grafico Rotazioni Cumulative	6
5.4	Grafico Caso Pessimo	7
6	Conclusioni	8

1 Introduzione

L'obiettivo del progetto è confrontare tra Alberi Binari di Ricerca (BST), AVL e Red-Black-Tree (RBT) il tempo medio di inserimento di una chiave quando l'albero contiene n chiavi e, ottenere per diversi valori di n , stime robuste dei tempi di esecuzione.

2 Richiami Teorici

Il costo dell'inserimento in un albero di ricerca dipende dalla lunghezza del cammino radice-foglia, ed è quindi proporzionale alla sua altezza h .

- **BST Semplice:** Il BST non impone alcun vincolo strutturale sulla forma dell'albero. Con input casuale uniforme, l'altezza attesa è $h = \mathcal{O}(\log n)$, ma nel caso peggiore (input ordinato) l'albero degenera in una lista concatenata con $h = \mathcal{O}(n)$.
- **Alberi AVL:** Gli alberi AVL mantengono un vincolo di bilanciamento stretto: per ogni nodo, la differenza di altezza tra il sotto-albero sinistro e destro (fattore di bilanciamento) deve essere al massimo 1 in valore assoluto. Una singola operazione di rotazione ha un costo temporale di $\mathcal{O}(1)$, in quanto consiste nel semplice scambio di un numero costante di puntatori. Questo garantisce un'altezza massima di circa:

$$h_{AVL} \leq 1.44 \log_2(n + 2)$$

assicurando $\mathcal{O}(\log n)$ nel caso peggiore. Quando un inserimento viola il vincolo, vengono eseguite rotazioni (singole o doppie) che risalgono l'intero cammino dal nuovo nodo fino alla radice per ripristinare il bilanciamento. Si distinguono quattro casi: rotazione sinistra, rotazione destra, rotazione sinistra-destra e rotazione destra-sinistra.

- **Alberi Red-Black:** I Red-Black-Tree associano a ogni nodo un colore (rosso o nero) in cui si richiede l'aggiunta di un singolo bit di informazione per l'attributo di questo colore e impongono le seguenti proprietà:
 1. Ogni nodo è rosso o nero
 2. La radice è nera
 3. Ogni foglia NIL è nera
 4. Un nodo rosso ha entrambi i figli neri (no due rossi consecutivi)
 5. Per ogni nodo, tutti i cammini verso le foglie contengono lo stesso numero di nodi neri (altezza nera)

Queste proprietà garantiscono un'altezza massima di:

$$h_{RBT} \leq 2 \log_2(n + 1)$$

Il vantaggio principale dei RBT rispetto agli AVL è che molte violazioni dopo un inserimento si risolvono tramite ricolorazioni, operazioni puramente logiche senza spostamento di nodi, rendendo le rotazioni meno frequenti rispetto all'AVL. Infatti, gli RBT, garantiscono al massimo 2 rotazioni, dove le restanti operazioni di bilanciamento sono ricolorazioni, che hanno un costo di $\mathcal{O}(1)$, mantenendo così un costo $\mathcal{O}(\log n)$ anche nel caso peggiore.

3 Struttura del Progetto

Il progetto è stato strutturato nel seguente modo, seguendo un'ottica di programmazione ad oggetti:

- **Codici delle Strutture Dati:** I file `BST.py`, `AVL.py` e `RBT.py` contengono i codici completi delle strutture dati. In particolare nei codici delle ultime due strutture dati il codice è stato alleggerito riciclando alcune parti del codice da `BST.py`, sfruttando l'*ereditarietà*.
- **KeyManager:** Questo file implementa la gestione controllata delle chiavi tramite il partizionamento di un array, garantendo la selezione di chiavi esterne all'albero e occupate (interne) in un tempo $\mathcal{O}(1)$.

- **Project:** Il file `Project.py` segue il Design Pattern *Factory*, utilizzato nella programmazione ad oggetti. Questo file consente di configurare comodamente il tipo di albero tramite stringhe identificative ("BST", "AVL", "RBT").
- **Experiment Setup & Runner:** `ExperimentSetup.py` genera la sequenza di dimensioni N basata su una progressione geometrica di valori di n da testare (da 1000 a 10.000.000 elementi) e si occupa del riempimento iniziale dell'albero. Mentre `ExperimentRunner.py` implementa l'effettivo ciclo di misurazione calcolando la mediana finale.

4 Algoritmo

Per ciascun valore di n identificato dalla progressione geometrica e per ogni struttura dati analizzata, il processo di misurazione si articola nei seguenti passi:

1. **Inizializzazione:** Viene istanziato un albero inizialmente vuoto (BST, AVL o RBT).
2. **Popolazione iniziale:** Sfruttando `KeyManager`, l'albero viene popolato inserendo n chiavi estratte casualmente dall'insieme globale. Al termine di questa fase, l'albero raggiunge l'esatta dimensione n , lasciando nel compartimento dell'array una sola chiave disponibile e non ancora utilizzata.
3. **Ciclo di misurazione:** Viene avviato un blocco ripetuto di 10 iterazioni. Ciascuna iterazione esegue in sequenza le seguenti operazioni:
 - (a) **Selezione ed Inserimento Cronometrato:** Viene prelevata l'unica chiave disponibile rimasta esclusa dall'albero e si misura in modo isolato il solo tempo di esecuzione dell'operazione `insert(k)` tramite la funzione di sistema `time.perf_counter()`. In questo istante la dimensione dell'albero sale temporaneamente a $n + 1$.
 - (b) **Rimozione ed Espulsione Silenziosa:** Si sceglie in modo puramente casuale una delle chiavi attualmente presenti all'interno dell'albero e la si rimuove tramite l'operazione `remove()` *senza cronometrare* l'esecuzione.
4. **Calcolo della statistica robusta:** Al termine delle 10 iterazioni, l'insieme dei tempi campionati viene aggregato calcolandone la mediana. Questo valore finale viene registrato come stima delle prestazioni di inserimento per la dimensione n corrente.

Questa specifica tecnica a coppie di *insert-remove* soddisfa due requisiti critici:


- **Dimensione Controllata:** Poiché l'eliminazione compensa esattamente l'inserimento precedente, viene garantito che prima di far partire il cronometro al giro successivo l'albero ritorni ad avere esattamente n chiavi.
- **Varietà Morfologica:** La continua espulsione e reinserimento di chiavi casuali altera costantemente e dinamicamente la topologia dei rami, modificando la struttura. In questo modo, le misurazioni avvengono su una famiglia di alberi le cui forme sono uniformemente distribuite nello spazio degli alberi possibili di dimensione n , evitando casi degeneri.

5 Risultati e Analisi


In seguito presentate e discusse le misurazioni eseguite in locale su MacBook Air M3 (con 16Gb di RAM) e su HP Pavilion (con 8Gb di RAM), poi raccolte all'interno di file in formato CSV ed elaborati all'interno di grafici.

5.1 Grafico Principale

Il grafico mostra il comportamento delle strutture dati nel caso medio, dove le chiavi vengono inserite con distribuzione casuale uniforme grazie al **KeyManager**.



Misurazioni MacBook Air M3



Misurazioni HP Pavilion

L'asse delle ascisse esprime la dimensione N dell'albero sfruttando una scala logaritmica (da 1.000 a 10.000.000 elementi). Tramite la scala logaritmica si è in grado di mostrare una curva di complessità teorica pari a $\mathcal{O}(\log n)$, che assume l'aspetto grafico di una retta.


Dall'osservazione delle figure, si nota:

- **Stabilità di BST e RBT:** Le progressioni relative a BST e RBT risultano costantemente schiacciate verso il basso lungo l'intero esperimento, denotando un'elevatissima efficienza d'esecuzione.
- **Inefficienza dell'AVL:** Di contro, la progressione associata all'albero AVL si distacca in modo netto spingendo visibilmente verso l'alto all'aumentare di N . Il vincolo di bilanciamento imposto dall'AVL (differenza di altezza massima pari a 1) si rivela estremamente inefficiente quando l'albero si fa altamente complesso. Ogni singola operazione innesca una catena di controlli e rotazioni correttive che, nel bilancio, pesano sul tempo complessivo.

Per quanto riguarda il confronto delle performance dei due laptop, si nota che il tempo medio più alto del MacBook si aggira attorno ai $1,2 \cdot 10^{-5}$ secondi, mentre quello più alto dell'HP Pavilion si aggira attorno ai $4 \cdot 10^{-5}$ secondi. Questo divario di performance è dovuto sia alla differenza di RAM tra i due laptop, sia alla differenza dei SO, dove MacOS ottimizza lo scheduling dei processi, mentre l'HP Pavilion, con Linux, risente della frammentazione della memoria fisica e dell'overhead delle system call.

5.2 Grafico dell'analisi asintotica

Il grafico mostra, come il precedente, il comportamento delle tre strutture dati in seguito all'inserimento casuale di chiavi.




Misurazioni MacBook Air M3

Il secondo grafico mantiene le stesse misurazioni del precedente, ma cambia la scala dell'asse delle ascisse: da logaritmica a lineare, con valori fino a $1,0 \cdot 10^7$. Questo cambio di prospettiva permette di osservare il comportamento asintotico delle strutture dati, ovvero come i tempi si stabilizzano al crescere di N . Una complessità $\mathcal{O}(\log n)$ su scala lineare produce una curva che cresce rapidamente per valori piccoli di N , per poi "appiattirsi" progressivamente. Questo è esattamente ciò che si osserva per BST e RBT, le cui curve convergono verso un andamento orizzontale. L'AVL invece, pur stabilizzandosi, lo fa su un valore significativamente più alto rispetto alle altre due strutture, confermando il peso costante delle rotazioni di riequilibrio.

Dall'osservazione delle figure, si nota:

- **Convergenza di BST e RBT:** Le curve di BST e RBT crescono inizialmente poco per poi "spianare", stabilizzandosi in modo netto su un andamento orizzontale sui grandi valori di N .
- **Divergenza dell'AVL:** Si nota invece che la progressione associata all'albero AVL, inizialmente sale molto più velocemente rispetto alle altre due strutture dati, per poi stabilizzarsi attorno a $1,1 \cdot 10^{-5}$ secondi per il MacBook e $3,5 \cdot 10^{-5}$ per l'HP. Questo dimostra graficamente che i vincoli dell'AVL rendono più difficile l'efficientamento.


Anche qui, come nella coppia di grafici precedente, si nota un calo di performance notevole nell'esecuzione del progetto sul secondo laptop.



Misurazioni HP Pavilion

5.3 Grafico Rotazioni Cumulative

Per la stampa di questo grafico l'inserimento è stato limitato alle chiavi [100, 500, 1000, 2500, 5000, 7500, 10000]. Viene mostrato il costo strutturale, rappresentato come numero totale cumulativo di rotazioni eseguite dalle tre strutture dati in funzione di N , durante l'inserimento di una sequenza di chiavi pre-ordinata.




Dall'osservazione della figura, si nota:


- **Assenza di rotazioni nel BST:** La progressione del BST rimane costantemente ancorata allo zero per tutta la durata del test. L'algoritmo non esegue alcuna rotazione, confermando l'assenza totale di manutenzione nel caso medio.
- **Costo di bilanciamento dell'AVL rispetto al RBT:** L'albero AVL mostra una pendenza superiore rispetto alla variante Red-Black. A causa del vincolo sulle altezze, ogni operazione di inserimento ha un'alta probabilità di innescare riequilibri. Al contrario, l'albero Red-Black gestisce gran parte delle violazioni strutturali tramite la ricolorazione dei nodi (operazione molto più leggera per la CPU), ricorrendo alle rotazioni dei nodi con una frequenza inferiore.

5.4 Grafico Caso Pessimo

Per la stampa di questo grafico, come per il precedente, l'inserimento è stato limitato alle chiavi [100, 500, 1000, 2500, 5000, 7500, 10000]. Vengono mostrati i tempi di inserimento delle suddette chiavi pre-ordinate all'interno delle tre strutture dati.



Misurazioni MacBook Air M3



Misurazioni HP Pavilion

Qui i due grafici sono più simili tra loro rispetto alla prima coppia, il primo rimane comunque più stabile. Nel secondo grafico si nota che all'inserimento del nodo 2500 si presenta un rallentamento che esce dall'andamento generale delle misurazioni. In generale dall'osservazione delle figure si nota:

- **Collasso prestazionale del BST:** La progressione del BST devia con una pendenza marcatamente lineare verso l'alto fin da subito. Privo di logiche di riequilibrio, l'albero subisce passivamente l'ordinamento dell'input inserendo ogni chiave come figlio destro della precedente. La struttura degenera a tutti gli effetti in una lista concatenata, portando l'altezza a $h = \mathcal{O}(n)$, confermando il limite della struttura dati non bilanciata.
- **Resistenza strutturale di AVL e RBT:** Al contrario, le progressioni di AVL e RBT rimangono schiacciate a ridosso dello zero. Entrambe le strutture intercettano lo sbilanciamento attivando

le rotazioni dei nodi l'efficienza asintotica logaritmica $\mathcal{O}(\log n)$ anche a fronte del peggior input possibile. Il confronto mostra come l'RBT si mantenga leggermente più efficiente dell'AVL grazie alla minore complessità delle operazioni di ricolorazione rispetto alle rotazioni.

6 Conclusioni

Lo studio ha permesso di analizzare il comportamento delle tre principali varianti di alberi binari di ricerca (BST, AVL e RBT), confermando le proprietà teoriche attraverso misurazioni su larga scala.

Le misurazioni effettuate evidenziano come la scelta della struttura dati ottimale sia strettamente dipendente dalla natura del carico di lavoro e dalla distribuzione dei dati in ingresso:

- Il **BST semplice** si è rivelato il più efficiente in scenari con input casuale uniforme. L'assenza di esecuzioni di riequilibrio annulla l'overhead sui puntatori, sfruttando la proprietà spontanea di bilanciamento indotta dalla casualità dei dati. Tuttavia dall'analisi del caso pessimo è stata evidenziata la fragilità del BST semplice e un calo di performance portando ad una complessità di $\mathcal{O}(n)$ non appena l'input presenta ordinamento crescente.
- L'**Albero AVL**, pur garantendo la complessità logaritmica nello scenario peggiore, risente fortemente del vincolo sulle altezze. Nelle applicazioni ad alta frequenza di scrittura, l'elevato numero di rotazioni necessarie a mantenere la struttura bilanciata introduce un rallentamento della CPU che ne penalizza i tempi rispetto alle altre strutture dati.
- L'**Albero Red-Black** si è dimostrato il miglior compromesso complessivo. Riuscendo a controllare lo sbilanciamento meglio rispetto all'AVL, riducendo il ricorso alle rotazioni dei nodi, risolvendo gran parte delle violazioni tramite ricolorazioni rosso-nere. Questa flessibilità consente di mantenere prestazioni ottime sia nel caso medio che di fronte a input degeneri, confermandolo come la struttura più robusta e versatile per scopi generali.

In conclusione l'analisi ha confermato che i meccanismi di bilanciamento rappresentano un vero e proprio "salvagente" dal punto di vista della complessità: pur introducendo un costo di manutenzione (evidente nell'AVL), essi salvano dalle degenerazioni a $\mathcal{O}(n)$ nel caso pessimo, garantendo una sicurezza e permettendo l'utilizzo nei sistemi software moderni (RBT nel File System di Linux) su scale di dati critiche. Questa unione tra efficienza algoritmica e gestione delle risorse è emersa durante la fase di testing: nei vari tentativi di esecuzione del progetto sui due laptop, è stato possibile osservare come le differenze hardware e di sistema operativo influenzino significativamente le performance. Il MacBook è riuscito a eseguirlo senza alcun intoppo, mentre l'HP ha risentito di rallentamenti e crash dovuti alla RAM limitata e alla gestione della memoria da parte del sistema operativo Linux.